Risultati degli Esperimenti di Caricamento (KBox) e di Chat

Di seguito presentiamo i risultati ottenuti da due set di esperimenti:

- 1. Esperimenti di caricamento in KBox (PDF, immagini, video)
- 2. Esperimenti di chat (funzione cost_of_message)

I valori sono riportati in tabelle, **senza tralasciare nulla**, e tutti i numeri dell'output originale sono inclusi.

1. Esperimenti di Caricamento in KBox

1.1 Risultati per PDF (pipeline HiRes/Fast, numero pagine {5,10,20,50,100})

| Pipeline | Pages | c_{page} | $t_{ m total}$ | Costo |
|----------|-------|---------------------|----------------|----------|
| HiRes | 5 | 0.01 | 2500 | 0.050088 |
| HiRes | 10 | 0.01 | 5000 | 0.100175 |
| HiRes | 20 | 0.01 | 10000 | 0.200350 |
| HiRes | 50 | 0.01 | 25000 | 0.500875 |
| HiRes | 100 | 0.01 | 50000 | 1.001750 |
| Fast | 5 | 0.001 | 2500 | 0.005088 |
| Fast | 10 | 0.001 | 5000 | 0.010175 |
| Fast | 20 | 0.001 | 10000 | 0.020350 |
| Fast | 50 | 0.001 | 25000 | 0.050875 |
| Fast | 100 | 0.001 | 50000 | 0.101750 |

(Osservazioni: $c_{\rm page}=0.01$ per la pipeline HiRes, 0.001 per la Fast. Il valore $t_{\rm total}$ è stimato come $\sim 500 \times {\rm Pages}$. Tutti i costi sono in dollari.)

1.2 Risultati per Immagini (3 risoluzioni, 2 modelli)

| Risoluzione | Modello | Costo |
|--------------------|------------|----------|
| 512×512 | GPT-40 | 0.002785 |
| 512×512 | GPT-4oMini | 0.000108 |
| 1024×1024 | GPT-40 | 0.006609 |
| 1024×1024 | GPT-4oMini | 0.000222 |
| 2048×2048 | GPT-40 | 0.021910 |
| 2048×2048 | GPT-4oMini | 0.000681 |

("Modello" indica il LLM (GPT-4
o o Mini) per generare la caption dell'immagine; costi in dollari.)

1.3 Risultati per Video (durata = 1 min, risoluzioni $\{512,\!1024,\!2048\},$ frame rate $\{1.0,\!0.5,\!0.2,\!0.1\},$ 2 modelli)

Ricordiamo che:

• Durata video = 1 minuto = 60s,

• rate $\in \{1.0, 0.5, 0.2, 0.1\}$ fps,

• $n_{frames} = 60 \times rate$,

 \bullet sampling_sec = 60 / n_frames.

(a) Risoluzione 512×512

| Rate (fps) | Modello | n_{-} frames | Costo |
|------------|------------|----------------|----------|
| 1.0 | GPT-40 | 60 | 0.121567 |
| 1.0 | GPT-4oMini | 60 | 0.004162 |
| 0.5 | GPT-40 | 30 | 0.060788 |
| 0.5 | GPT-4oMini | 30 | 0.002085 |
| 0.2 | GPT-40 | 12 | 0.024320 |
| 0.2 | GPT-4oMini | 12 | 0.000838 |
| 0.1 | GPT-40 | 6 | 0.012164 |
| 0.1 | GPT-4oMini | 6 | 0.000423 |

(b) Risoluzione 1024×1024

| Rate (fps) | Modello | n_{-} frames | Costo |
|------------|------------|----------------|----------|
| 1.0 | GPT-40 | 60 | 0.351068 |
| 1.0 | GPT-4oMini | 60 | 0.011047 |
| 0.5 | GPT-40 | 30 | 0.175538 |
| 0.5 | GPT-4oMini | 30 | 0.005527 |
| 0.2 | GPT-40 | 12 | 0.070219 |
| 0.2 | GPT-4oMini | 12 | 0.002215 |
| 0.1 | GPT-40 | 6 | 0.035113 |
| 0.1 | GPT-4oMini | 6 | 0.001111 |

(c) Risoluzione 2048×2048

| Rate (fps) | Modello | n_{-} frames | Costo |
|------------|------------|----------------|----------|
| 1.0 | GPT-40 | 60 | 1.269068 |
| 1.0 | GPT-4oMini | 60 | 0.038587 |
| 0.5 | GPT-40 | 30 | 0.634538 |
| 0.5 | GPT-4oMini | 30 | 0.019297 |
| 0.2 | GPT-40 | 12 | 0.253820 |
| 0.2 | GPT-4oMini | 12 | 0.007723 |
| 0.1 | GPT-40 | 6 | 0.126914 |
| 0.1 | GPT-4oMini | 6 | 0.003865 |

2. Esperimenti di Chat (cost_of_message)

Parametri:

- $\bullet \ \mathtt{max_pairs} = \{10{,}20{,}30\}$
- $\bullet \ \mathtt{n_kbox} = \{1,\!2,\!3\}$
- $\bullet \ \texttt{r_per_kbox} = \{5{,}10{,}15\}$
- $\bullet \ \mathtt{model} = \{\mathrm{GPT}\text{-}4\mathrm{o},\,\mathrm{GPT}\text{-}4\mathrm{oMini}\}$

Tabella dei risultati (costo in dollari):

| max_pairs | n_kbox | r_per_kbox | Model | Costo |
|-----------------|----------------|------------|--------------|--|
| 10 | 1 | 5 | GPT-4o | 0.022270 |
| 10 | 1 | 5 | GPT-4oMini | 0.000732 |
| 10 | 1 | 10 | GPT-40 | 0.029770 |
| 10 | 1 | 10 | GPT-4oMini | 0.000958 |
| 10 | 1 | 15 | GPT-40 | 0.037270 |
| 10 | 1 | 15 | GPT-4oMini | 0.001182 |
| 10 | 2 | 5 | GPT-40 | 0.029770 |
| 10 | 2 | 5 | GPT-4oMini | 0.000958 |
| 10 | 2 | 10 | GPT-4o | 0.044770 |
| 10 | 2 | 10 | GPT-4oMini | 0.001408 |
| 10 | $\overline{2}$ | 15 | GPT-40 | 0.059770 |
| 10 | $\overline{2}$ | 15 | GPT-4oMini | 0.001857 |
| 10 | 3 | 5 | GPT-40 | 0.037270 |
| 10 | 3 | 5 | GPT-4oMini | 0.001182 |
| 10 | 3 | 10 | GPT-40 | 0.059770 |
| 10 | 3 | 10 | GPT-4oMini | 0.001857 |
| 10 | 3 | 15 | GPT-40 | 0.082270 |
| 10 | 3 | 15 | GPT-4oMini | 0.002533 |
| 20 | 1 | 5 | GPT-40 | 0.032270 |
| 20 | 1 | 5 | GPT-4oMini | 0.001032 |
| 20 | 1 | 10 | GPT-40 | 0.039770 |
| $\frac{20}{20}$ | 1 | 10 | GPT-4oMini | 0.001257 |
| $\frac{20}{20}$ | 1 | 15 | GPT-40 | 0.047270 |
| $\frac{20}{20}$ | 1 | 15 | GPT-4oMini | 0.001483 |
| $\frac{20}{20}$ | 2 | 5 | GPT-40 | 0.039770 |
| 20 | 2 | 5 | GPT-4oMini | $\begin{vmatrix} 0.003770 \\ 0.001257 \end{vmatrix}$ |
| $\frac{20}{20}$ | 2 | 10 | GPT-40 | 0.054770 |
| 20 | 2 | 10 | GPT-4oMini | 0.001708 |
| $\frac{20}{20}$ | 2 | 15 | GPT-40 | 0.069770 |
| $\frac{20}{20}$ | 2 | 15 | GPT-4oMini | 0.002158 |
| $\frac{20}{20}$ | 3 | 5 | GPT-40 | 0.047270 |
| 20 | 3 | 5 | GPT-4oMini | 0.001483 |
| 20 | 3 | 10 | GPT-40 | 0.069770 |
| 20 | 3 | 10 | GPT-4oMini | 0.002158 |
| $\frac{20}{20}$ | 3 | 15 | GPT-40 | 0.092270 |
| $\frac{20}{20}$ | 3 | 15 | GPT-4oMini | 0.002832 |
| 30 | 1 | 5 | GPT-40 | 0.042270 |
| 30 | 1 | 5 | GPT-4oMini | 0.001332 |
| 30 | 1 | 10 | GPT-40 | 0.049770 |
| 30 | 1 | 10 | GPT-4oMini | 0.001558 |
| 30 | 1 | 15 | GPT-40 | 0.057270 |
| 30 | 1 | 15 | GPT-4oMini | 0.001783 |
| 30 | 2 | 5 | GPT-4o | $\begin{vmatrix} 0.001733 \\ 0.049770 \end{vmatrix}$ |
| 30 | $\frac{2}{2}$ | 5 | GPT-4oMini | 0.001558 |
| 30 | $\frac{2}{2}$ | 10 | GPT-4o | $\begin{vmatrix} 0.001990 \\ 0.064770 \end{vmatrix}$ |
| 30 | $\frac{2}{2}$ | 10 | GPT-4oMini | 0.002007 |
| 30 | $\frac{2}{2}$ | 15 | GPT-4o | 0.079770 |
| 30 | $\frac{2}{2}$ | 15 | GPT-4oMini | 0.002458 |
| 30 | $\frac{2}{3}$ | 5 | GPT-4o | 0.002430 0.057270 |
| 30 | 3 | 5 | GPT-4oMini | 0.001783 |
| 30 | 3 | 10 | GPT-4o | $\begin{vmatrix} 0.001733 \\ 0.079770 \end{vmatrix}$ |
| 30 | 3 | 104 | GPT-4oMini | 0.019110 |
| 30 | 3 | 15 | GPT-40 | 0.002438 0.102270 |
| 30 | 3 | 15 | GPT-4oMini | $\begin{vmatrix} 0.102270 \\ 0.003132 \end{vmatrix}$ |
| | J | 10 | O1 1-40MIIII | 0.003134 |

(Interpretazione: ogni riga specifica i parametri max_pairs, n_kbox, r_per_kbox, model e il costo ottenuto in dollari.)

Osservazioni finali:

- **PDF**: il costo cresce linearmente con il numero di pagine e dipende dal pipeline (HiRes vs. Fast).
- Immagini: il costo aumenta con la risoluzione. L'uso di GPT-40 per la caption risulta molto più costoso di GPT-40Mini (fattore $\sim 20-30\times$).
- Video (1 minuto): al crescere del frame rate e della risoluzione, il costo aumenta; GPT-40 rimane più dispendioso di GPT-40Mini.
- Chat: dipende da max_pairs, n_kbox, r_per_kbox e dal modello (GPT-4o / GPT-4oMini). Anche qui GPT-4o risulta $\sim 20-30\times$ più costoso.

Tutti i valori sono riportati senza tralasciare nulla, in strutture/tabelle adeguate.

Fine.